AI4：支持向量机与群智能算法优化

A 问题是什么

给一批带标签的数据，支持向量机（SVM）怎样找到分类边界？模型的超参数又应该怎样选择？本项目分两段：Basic 在小型二分类数据上训练线性和 RBF-SVM，理解间隔、核函数和验证集；Advance 自行实现粒子群优化（PSO），在相同评价预算下与随机搜索比较，检验“更复杂的搜索是否值得”。

阶段	工作量安排	难度	完成后的能力
Basic	一周内约 10-20 小时	easy	用小数据训练 SVM，解释 C、gamma 与分类边界
Advance	完成 Basic 后再用六周	medium	实现 PSO、建立无泄漏评价、比较准确率与搜索成本

不要求 GPU。Basic 可使用成熟 SVM 库，不要求一周内手写 SMO。参考 v0：08-svm；原版包含 SMO、GA、混合 PSO 和特征选择。本说明缩小主线：**PSO 调 C/gamma 必做，联合特征选择和 GA 选做**，原版全部 TODO 不作为七周任务的前置条件。

Basic：先认识分类器，再讨论怎样优化它

1 学习目标与需要回答的问题

完成 Basic 时按 Q1-Q5 提交回答，Q5 附手算表。

编号	需要回答的问题	回答应包含的内容
Q1	SVM 接收什么、输出什么？	特征与类别标签；决策值的符号决定预测类别
Q2	什么是最大间隔和支持向量？	边界附近的关键样本；间隔不是训练准确率
Q3	C 与 gamma 分别影响什么？	C 控制违反间隔的惩罚；gamma 控制 RBF 相似性的尺度
Q4	为什么不能用测试集挑参数？	训练、开发、最终测试职责不同；标准化也只能在训练部分拟合
Q5	f(x)=2x-1，标签 y 为 -1/+1，下面四点的预测和 hinge loss 是多少？	用 sign(f) 判类，用 max(0,1-y*f) 算损失

点	x	y
1	-1	-1
2	0	-1
3	0.6	+1
4	0.4	+1

2 本周用到的 SVM 概念（先读这段）

边界是一条分数为零的线。 线性 SVM 先计算 $f(x)=w\cdot x+b$。正负号决定类别，$|f(x)|/||w||$ 才是到超平面的几何距离。分数不是自动校准好的概率。

分对还不够，希望留出间隔。 $y*f(x)>=1$ 表示满足单位函数间隔；位于正确一侧但太靠近边界，也会有 hinge loss。软间隔允许违反约束，用 C 调节惩罚强度。

核函数让边界弯曲。 RBF 核计算 exp(-gamma*距离平方)，距离近的样本相似度高。gamma 大时相似度随距离衰减更快；不等于“参数越大越好”。

名字	人话	Basic 要不要
StandardScaler	用训练数据的均值和标准差统一尺度	要
线性 SVM	学一条直线或超平面	要，作为对照
RBF-SVM	用相似度表达非线性边界	要
SMO	求解 SVM 对偶问题的一种算法	暂不要求手写
PSO	在候选超参数之间搜索	Advance 再做

编号	材料	建议用法
B1	scikit-learn：SVM	看分类、核函数和参数，不必先读全部推导
B2	v0 SVM 项目说明	了解已有数据和完整框架，区分本次必做范围
B3	UCI：MADELON	Advance 数据；Basic 先用小数据

3 代码任务：可解释的小型分类实验

使用 Iris 的两个类别，或固定种子生成 200-500 个二维二分类点。自己编写一个独立 Basic 脚本，避免被原版 SMO 的 TODO 阻塞。

1. 固定分层训练/开发/测试划分，如 60%/20%/20%，记录样本数。
2. 将 StandardScaler 和 SVC 放入同一个 Pipeline；只在训练集 fit。
3. 比较线性核与 RBF 核。只用开发集选择少量 C/gamma 配置。
4. 冻结配置后在测试集评价一次，报告 accuracy、混淆矩阵与样本数。
5. 二维数据画边界和支持向量；高维数据不能把任意二维投影当成完整边界。

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC

model = make_pipeline(
    StandardScaler(),
    SVC(kernel="rbf", C=1.0, gamma="scale"),
)
# 在自己的脚本中准备 X_train、y_train，再调用 fit 和 predict。
```

依赖可用 python -m pip install numpy scikit-learn matplotlib 安装。上述片段是建模示意，数据划分、记录和绘图由学生补充，不是已完成的实验。

4 用一个小例子核对

点	f(x)	y*f(x)	预测	hinge loss
1	-3	3	-1，正确	0
2	-1	1	-1，正确	0
3	0.2	0.2	+1，正确	0.8
4	-0.2	-0.2	-1，错误	1.2

准确率为 3/4，平均 hinge loss 为 0.5。第 3 点虽分对，仍违反间隔要求。本表只算损失项，没有加入权重正则项，因此不是完整训练目标。

5 Basic 提交与验收

提交源码、数据划分、真实指标、边界图或预测表、Q1-Q5。验收看测试隔离、标准化位置和原理解释，不设必须超过某个分数的门槛。

Advance：用 PSO 搜索参数，检验群体搜索是否有用

1 学习目标与难度

研究问题是：**同样允许评价 B 个候选配置，PSO 是否比随机搜索更有效？** SVM 在给定超参数下的训练与外层超参数搜索是两件事，不能把二者混为一个优化问题。

Goal	学习目标与完成要求	难度
G1	区分模型训练、超参数搜索与最终评价	easy
G2	固定数据、CV 折、搜索范围与评价预算	easy
G3	自行实现连续 PSO，先在 Sphere 函数上验证	medium
G4	接入 RBF-SVM，记录参数、分数与调用次数	medium
G5	与默认参数、随机搜索比较，至少 3 个种子	medium
G6	从第 5 节选一个方向阅读	按方向
G7	短报告与 presentation	medium

G1-G7 均需完成，G6 只选一个。主线固定全部特征，只搜索两个连续参数，算力允许再扩大规模。

2 会用到的方法（同样先读这段）

一个粒子就是一组参数。 令位置为 (u,v)，再转成 C=10^u、gamma=10^v。这样移动一个单位表示参数改变十倍，适合搜索跨数量级的参数。

粒子会记住自己和群体的好位置。 pbest 是该粒子历史最好位置，gbest 是群体历史最好位置；两个随机数让探索保留随机性。

```
velocity = w*velocity + c1*r1*(pbest-position)
                      + c2*r2*(gbest-position)
position = position + velocity
loss = 1 - 训练部分内部的平均 CV accuracy
```

设置速度限制、位置边界和固定种子；历史最优值要复制保存，不能引用后来还会变化的数组。只在真实评价后更新 pbest/gbest。

编号	材料	建议用法
A1	Kennedy 与 Eberhart：Particle Swarm Optimization	主文献；理解位置、速度、个体与群体记忆
A2	scikit-learn：SVM	核参数与训练接口
A3	v0：算法与评价协议	参考 pso.py、objective.py，区分完整混合实验与本项目主线
A4	MADELON 官方数据页	理解高维噪声、特征选择与数据划分

3 方法实现与过程展示（G2-G4）

先在 Sphere(x)=sum(x*x) 上检查：固定种子可重复、位置不越界、历史最优损失不增、实际候选评价次数不超过预算。再接入 SVM。

可使用 MADELON 官方 Training 做搜索，官方带标签 Validation 作为**本项目封存的最终测试集**；名称是 Validation，不代表能反复看它调参。不使用无公开标签 Test。机器较慢可在 Training 内固定抽样，并把规模写清。

统一协议：

1. 训练部分内部固定分层 3 折 CV；每折分别拟合标准化，不能先对全训练部分标准化再 CV。
2. 搜索范围如 $u \in [-3,3]$、$v \in [-4,1]$；RandomSearch 与 PSO 使用相同范围与折划分。
3. 每种搜索每个种子评价 B=30-60 个候选即可；初始化粒子也计入 B。
4. 缓存策略保持一致，同时报告提议数、唯一候选数与 SVC 拟合次数。
5. PSO 参数和预算在测试前确定，最终测试只用于报告已冻结方法。

采用本说明的独立连续 PSO 入口即可。v0/examples/03_quick_demo.py 调用的是更大的混合任务，须完成其相关 TODO 才能运行；不能把它当作本次的现成完整答案。

4 比较方法并解释结果（G5 · medium）

所有方法使用相同数据和预处理。至少 3 个搜索种子，固定数据切分；种子波动描述搜索稳定性，不等于测试抽样置信区间。

方法	CV accuracy	最终 accuracy	候选评价数	拟合次数/耗时
默认 RBF-SVM	待测	待测	1 个配置	待测
随机搜索	待测	待测	B	待测
PSO	待测	待测	B	待测

画横轴为候选评价次数的历史最优曲线，不直接比较迭代轮数。PSO 的种群大小不同，每轮调用数也不同。若随机搜索更好或差异小，应如实报告，并讨论维数、预算和噪声。

5 可选方向（G6 · 选择一个）

以阅读为主，不另加代码要求；实现可作为拓展。

方向	难度	重点理解的问题	对应资料
G6-A：GA 对照	medium	选择、交叉、变异与粒子移动怎样不同？GA 属进化算法	A3

方向	难度	重点理解的问题	对应资料
G6-B：特征选择	hard	二进制掩码与 C/gamma 怎样联合编码？如何惩罚过多特征？	A3、A4
G6-C：SMO	hard	为什么可以轮流优化两个对偶变量？	A2、A3

若做有监督特征筛选，筛选也必须在 CV 训练折内部拟合；不要把全体训练标签筛出来的特征用于证明折内无泄漏。最终封存集始终不能参与筛选或初始化先验。

6 提交与讲解（G7 · medium）

提交 PSO 源码、基线、数据卡、CV 配置、多种子结果、评价次数曲线、耗时和阅读笔记。Presentation 讲清“优化器优化谁、每次评价花了什么、为何比较公平”。不要求 PSO 必须获胜。

B 工作量安排与 Checkpoint

Basic：一周，约 10-20 小时

内容	预计用时
间隔、核函数与 Q5	3-5 小时
数据切分、标准化与 SVM	3-5 小时
开发集比较、最终评价和图	3-5 小时
整理材料	1-2 小时
合计	约 10-17 小时

Checkpoint：两种核的真实结果、无泄漏切分、Q1-Q5。

Advance：在 Basic 基础上追加六周

时间	对应 Goal 与难度	主要任务	Checkpoint
第 1-2 周	G1、G2；G3：medium	固定协议，在 Sphere 上实现 PSO	更新过程、边界与预算检查
第 3-4 周	G4、G5：medium	接入 CV，多种子比较随机搜索	主表、调用次数曲线、耗时
第 5-6 周	G6 按方向；G7：medium	选读、整理报告与讲解	能解释成本和搜索稳定性

C 问题的来龙去脉与发展过程

从分开样本到保留间隔。 SVM 用间隔与误差惩罚刻画分类边界，核函数让这种思路扩展到非线性关系；参数选择仍需要与训练分开的评价流程。SVM 文档

从求解模型到搜索黑盒配置。 外层每次只拿到一次训练/CV 的结果，可以将其视为昂贵的黑盒评价。1995 年提出的 PSO 用个体和群体历史信息引导搜索；它提供搜索策略，不承诺每次都找到最优参数。PSO 原论文

从最好分数到有限预算比较。 高维噪声数据让特征与参数选择更困难。公平比较需要同时记录评价次数、拟合次数和波动，本项目先用两个参数掌握这一实验思想，再阅读混合优化。MADELON