AI7：N-gram 语言模型文本生成器

A 问题是什么

不用神经网络，只统计“前几个字后面出现过什么”，能不能生成一段文本？N-gram 模型把上下文限制为前 N-1 个 token，用计数估计下一个 token 的概率。Basic 完成计数与采样；Advance 比较 N、平滑和困惑度，研究局部通顺、数据稀疏与复述原文之间的关系。

阶段	工作量安排	难度	完成后的能力
Basic	一周内约 10-20 小时	easy	用字典训练 bigram，按概率生成文本
Advance	完成 Basic 后再用六周	medium	处理未知符号与零概率，正确比较困惑度与生成效果

Python 标准库即可，不需要 GPU 或大模型 API。参考 v0：24-NGram；下文命令在该目录运行。课程核心是透明的计数模型，生成结果不代表具有事实知识。

Basic：用计数和抽样完成续写

1 学习目标与需要回答的问题

提交 Q1-Q5，Q5 附完整计数与概率。

编号	需要回答的问题	回答应包含的内容
Q1	N=2 时模型看多长上下文？	只看前 1 个 token；N 包括正在预测的 token
Q2	模型里保存什么？	上下文元组到后继计数的字典，而非神经网络权重
Q3	为什么不能每次都选最多的后继？	贪心与按概率抽样不同；抽样允许多个合理续字
Q4	START、END、随机种子有什么用？	开始/停止规则，以及可重复的随机采样
Q5	tokens=[我,爱,北京,爱,你]，N=2，哪些转移出现几次？	补 START/END；算“爱”之后两个后继的概率

2 本周用到的语言模型（先读这段）

token 是切分单位。 中文可按字，英文可按空格分词。Q5 特意把“北京”视为一个 token；正式字符级实验则会拆为“北”“京”。所有结果必须说明切分方式。

条件概率来自计数。 如果“爱”后接“北京”和“你”各一次，两者概率各 1/2。模型不理解地名或人称，只保存观察到的统计关系。

```
P(下一个 token | 上下文)
= 该上下文后接该 token 的次数 / 该上下文出现的总次数
```

生成就是移动窗口。 取最近 N-1 个 token 查分布、加权抽样、追加输出，再重复；遇 END 或达到长度上限就停止。N=1 时上下文是空元组，退化为词频抽样。

编号	材料	建议用法
B1	Stanford：N-gram Language Models	先读 N-gram 与计数例子，困惑度后读

编号	材料	建议用法
B2	v0 实现指南	函数接口、边界与自测
B3	v0 项目说明	自带语料、命令与模型观察方法

3 代码任务：计数与文本生成

1. 用 UTF-8 读取短语料，统一字符/词切分规则。
2. 每个独立序列前补 N-1 个 START，后补一个 END；不要把无关文档直接连成真实上下文。
3. 在 model.py 完成上下文→后继计数，支持 N=1。
4. 在 generate.py 按计数加权抽样，固定种子，设最大长度。
5. 打印两个上下文的后继分布，生成 N=1、2、3 的样例，记录实际长度与停止原因。

```
python src/check.py
python src/main.py inspect --n 2 --context 爱
python src/main.py generate --n 2 --length 200 --seed 42
```

v0 的计数、生成、评估函数有 TODO。Basic 只完成计数与生成；check.py 中评估相关项可等 Advance，不能把部分通过写成全部通过。语料中若没有“爱”，换一个确实出现的上下文。

采到 END 可以早停，不要为了凑 200 字丢弃短结果；如需多段展示，固定生成段数并保留全部样例。未见上下文要明确停止或回退，不能悄悄改成随机字符。

4 用一个小例子核对

上下文	后继计数	概率
START	我：1	1
我	爱：1	1
爱	北京：1，你：1	各 1/2
北京	爱：1	1
你	END：1	1

从 START 生成“我 爱 你 END”的概率是 1×1×1/2×1=1/2。生成也可能绕过“北京 爱”再回来，不等于从训练文本中随机截一段。

5 Basic 提交与验收

提交计数/采样代码、真实模型条目、固定种子生成结果和 Q1-Q5。验收看概率是否归一、N=1 和停止条件是否正确，不以生成内容像不像人作为唯一标准。

Advance：文本更像原文，模型就更好吗

1 学习目标与难度

Advance 用未见文本检验：N **增大后，局部搭配改善是否伴随稀疏和过拟合？** 生成观感与预测概率是两类证据，要分别报告。

Goal	学习目标与完成要求	难度
G1	解释稀疏、零概率、平滑与过拟合	easy
G2	先切分语料，再建立训练词表与各阶计数	easy
G3	实现 log 概率、困惑度与 Laplace 平滑	medium
G4	比较 N=1、2、3、4 的统计与生成	easy
G5	联合分析训练/测试 PPL、单次上下文与复述	medium
G6	从第 5 节选一个方向阅读	按方向
G7	代码、图表、短报告和 presentation	medium

G1-G7 均需完成，G6 只选一个。没有固定的最低困惑度要求。

2 会用到的评估（同样先读这段）

困惑度是在评价真实文本。 对测试文本每个真实后继计算条件概率，取平均负 log 概率再指数化。它不是对生成样例的“流畅度打分”。

```
PPL = exp(−sum(log P(真实后继 | 上下文)) / M)
Laplace：P(w | h) = (count(h,w)+1) / (count(h)+|V|)
```

M 是纳入评价的目标 token 数，是否含 END 要固定。任一目标概率为 0，无平滑 PPL 就是无穷；不要用任意小常数偷偷替代后仍称“无平滑”。

未知符号要事先定义。 训练词表包括 END、UNK，不把 START 当普通可生成目标。可把训练中的低频词映射为 UNK，再把开发/测试的词表外 token 映射到同一 UNK；不能借测试文本扩词表。

编号	材料	建议用法
A1	Stanford N-gram 章节	主文献；困惑度、未知词、平滑与插值
A2	v0 评估接口指南	对照数值与自测，补充正式未知词协议
A3	v0 发展背景与阅读路线	香农的逐阶文本近似及开放探索

3 方法实现与过程展示（G2-G4）

1. 按完整文档或连续大段切分训练/开发/测试，如 60%/20%/20%；不能随机打散 token 再切分。
2. 分别在各段补边界符号和滑窗，禁止跨越切分边界计数。
3. 固定同一词表、分词器和测试目标 token 集，用 N=1-4 建模。
4. 分别计算无平滑与 Laplace PPL；测试未见上下文在 Laplace 下可得到均匀分布。
5. 记录词表规模、OOV 比例、上下文数、只出现一次的上下文比例和模型存储量。

可用简单概率核对评估：两个目标概率分别为 1/2 和 1/4，则 PPL=exp(-(ln(1/2)+ln(1/4))/2)=sqrt(8)≈2.828427。

```
python src/check.py
python src/main.py compare --data data/hongloumeng.txt
```

compare 是现有 80%/20% 两段切分教学入口，完成相应 TODO 后才可运行。正式实验若调整平滑、词表或采样，需要自行加入开发集与 UNK 处理，不能把该入口当作已经满足全部研究协议。

4 比较方法并解释结果（G5 · medium）

每阶都填无平滑/加一两种结果，生成样例固定 3 个种子并保留，不只挑最通顺的一段。

N	训练 PPL	测试 PPL：无平滑/加一	单次上下文比例	样例观察
1	待测	待测	待测	待分析
2	待测	待测	待测	待分析
3	待测	待测	待测	待分析
4	待测	待测	待测	待分析

画 N 与 PPL 的关系，无穷值单独标记，不强行连线。检索生成片段是否在训练原文中出现，记录最长连续匹配等简单证据。更大 N 不保证测试 PPL 更低；不同 token 化或词表的 PPL 也不能直接横比。

5 可选方向（G6 · 选择一个）

以阅读为主；愿意实现时只选一项。

方向	难度	重点理解的问题	对应资料
G6-A：回退与插值	medium	高阶没见过时怎样使用低阶统计？	A1
G6-B：温度与 Top-k	easy	采样多样性与原分布困惑度为何不同？	A1、A3
G6-C：文风鉴别	medium	两个模型对同一文本赋概率能比较什么？	A3

字符级与词级可比较样例、速度与词表规模；若要比较压缩或概率性能，应统一计量单位，不能直接比较不同分词的 PPL。

6 提交与讲解（G7 · medium）

提交源码、语料来源与许可、切分、词表规则、完整自测结果、PPL 表/图、生成样例与阅读笔记。Presentation 回答：一个计数字典学到了什么，哪些依赖关系超出了它的上下文长度？

B 工作量安排与 Checkpoint

Basic：一周，约 10-20 小时

内容	预计用时
token、计数与 Q5	3-4 小时
构建模型与检查条目	3-5 小时
加权采样与边界	3-5 小时
整理回答与样例	1-2 小时
合计	约 10-16 小时

Checkpoint：bigram 手算相符、固定种子可重复、Q1-Q5。

Advance：在 Basic 基础上追加六周

时间	对应 Goal 与难度	主要任务	Checkpoint
第 1-2 周	G1、G2；G3：medium	固定切分/词表，实现 PPL 和平滑	sqrt(8) 核对、未知词策略
第 3-4 周	G4、G5：medium	四阶模型比较与复述检查	PPL 图、统计表、生成样例
第 5-6 周	G6 按方向；G7：medium	选读与报告	解释稀疏、平滑与过拟合

C 问题的来龙去脉与发展过程

从相依事件到有限上下文。 马尔可夫式建模用有限历史近似完整历史，使复杂文本能转成可统计的转移。N-gram 把这个思想落实为计数和条件概率。N-gram 教材

从模仿文本到处理未见事件。 上下文越长，精确匹配越稀少，平滑与回退成为关键。训练文本很像并不足够，还要评价未见文本的概率与复述程度。

从离散计数到连续表示。 神经语言模型用可共享的向量参数表示上下文，但仍需要定义预测目标、划分数据和采样方法。本项目用简单模型理解这些共同问题，不把计数模型与大型语言模型的能力等同。